گزارش فاز اول: فهم مسئله، شناخت داده و تحلیل اکتشافی

درس تحلیل داده - پاییز ۱۴۰۵

نام دانشجو: فرزان محمدیان دلویی

شماره دانشجویی: ۴۰۲۱۰۰۵۱۵

مسیر انتخابی: مسیر الف (NYC TLC Trip Record)

۱. صورت‌بندی مسئله و تعریف سؤال تحلیلی

هدف اصلی این پروژه، پیش‌بینی و تحلیل تقاضای ساعتی سفرهای ناوگان تاکسی زرد شهر نیویورک در مناطق مختلف (`Taxi Zones`) است. خروجی این تحلیل به سیستم‌های مدیریت ناوگان کمک می‌کند تا تخصیص خودروها در سطح شهر را بر اساس تقاضای متغیر زمانی و مکانی بهینه‌سازی کنند.

- **متغیر هدف:** تعداد سفرهای شروع‌شده در هر ناحیه طی یک بازه زمانی ساعتی (`trip_count`).
- **واحد تحلیل:** جفت «شناسه منطقه مبدأ - بازه زمانی ساعتی».
- **سؤال اصلی:** آیا می‌توان با استفاده از ویژگی‌های چرخه‌ای زمان و الگوی تاریخی تقاضا، حجم سفرهای ساعتی مناطق مختلف را پیش‌بینی کرد؟

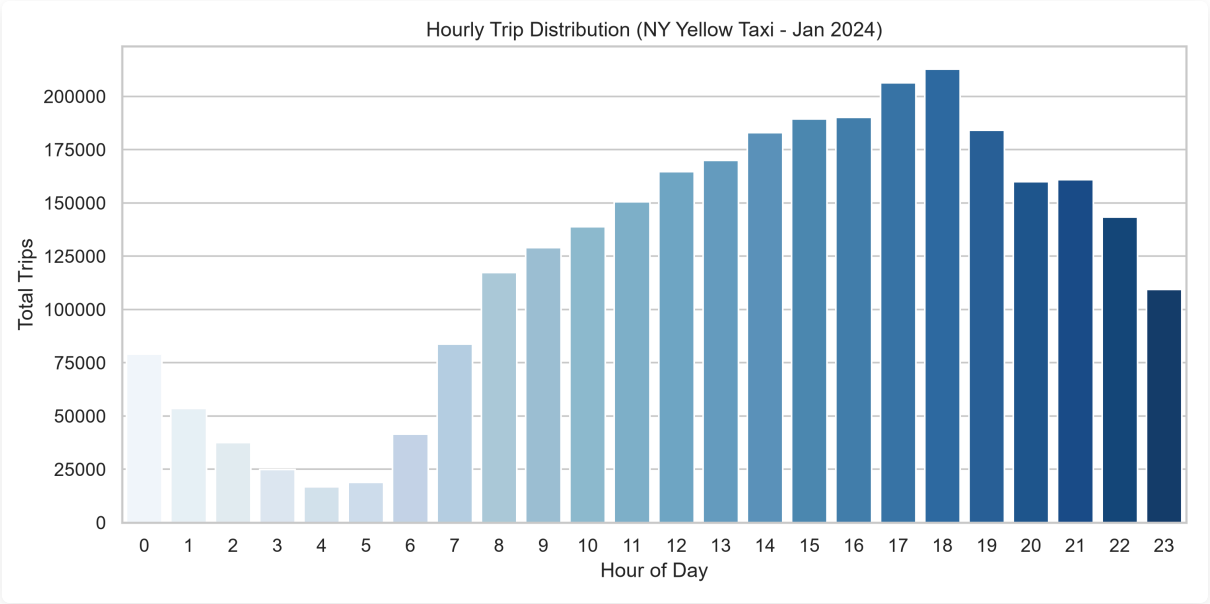
۲. ممیزی ساختار و کیفیت داده‌ها (Data Quality Audit)

تحلیل بر روی داده‌های رسمی تاکسی زرد نیویورک (مربوط به ژانویه ۲۰۲۴) انجام شد. نتایج ممیزی اولیه به شرح زیر است:

شاخص ممیزی	مقدار / تعداد	توضیحات و تصمیم تحلیلی
تعداد کل رکوردها (سفرها)	۲,۹۶۴,۶۲۴	حجم کل مشاهدات بارگذاری شده از فایل parquet
تعداد ویژگی‌ها (ستون‌ها)	۱۹	شامل زمان، مسافت، کرایه، شناسه مکان‌ها و...
مقادیر گمشده (Missing Values)	۱۴۰,۱۶۲ رکورد	مشاهده شده در ستون‌های passenger_count و RatecodeID
کرایه‌های منفی یا غیرممکن	۳۷,۴۴۸ رکورد	اشکالات سیستمی یا اصلاح تراکنش (نیاز به پاک‌سازی در فاز ۲)
مسافت صفر با کرایه بالا (>۵۰$)	۸,۶۸۱ رکورد	سفرهای کنسل شده یا خطای سنجش مسافت GPS

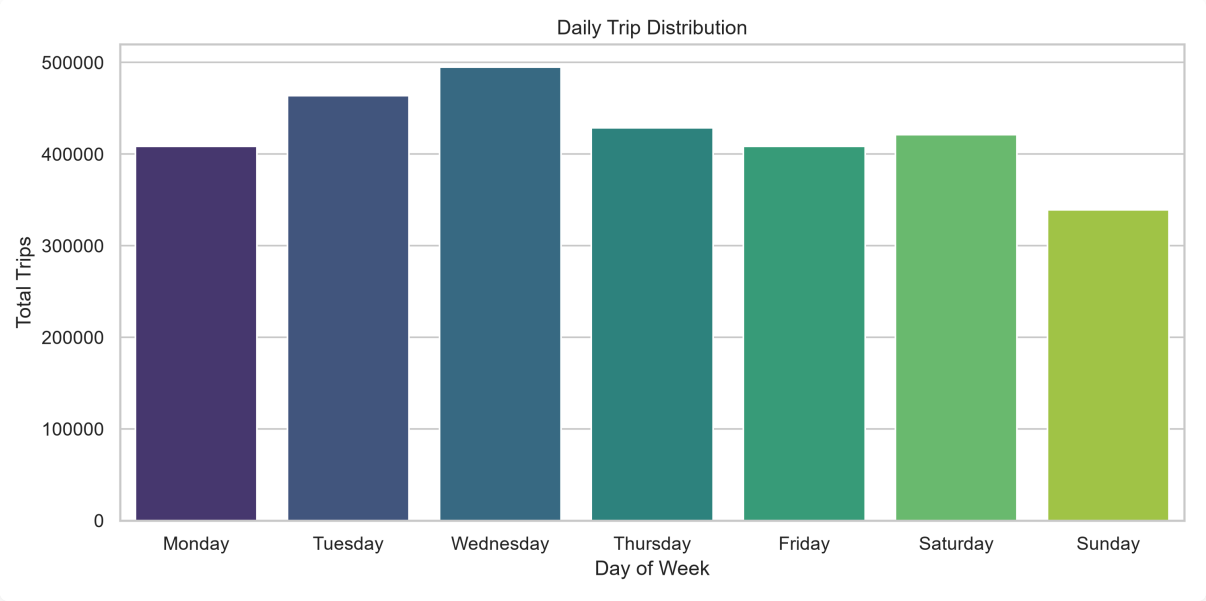
۳. تحلیل اکتشافی (EDA) و الگوهای تصویری داده‌ها

برای درک عمیق‌تر رفتار داده‌ها، بررسی‌های تک‌متغیره و چندمتغیره روی بعد زمان و مکان صورت گرفت که نتایج آن در قالب نمودارهای زیر استخراج شده است:



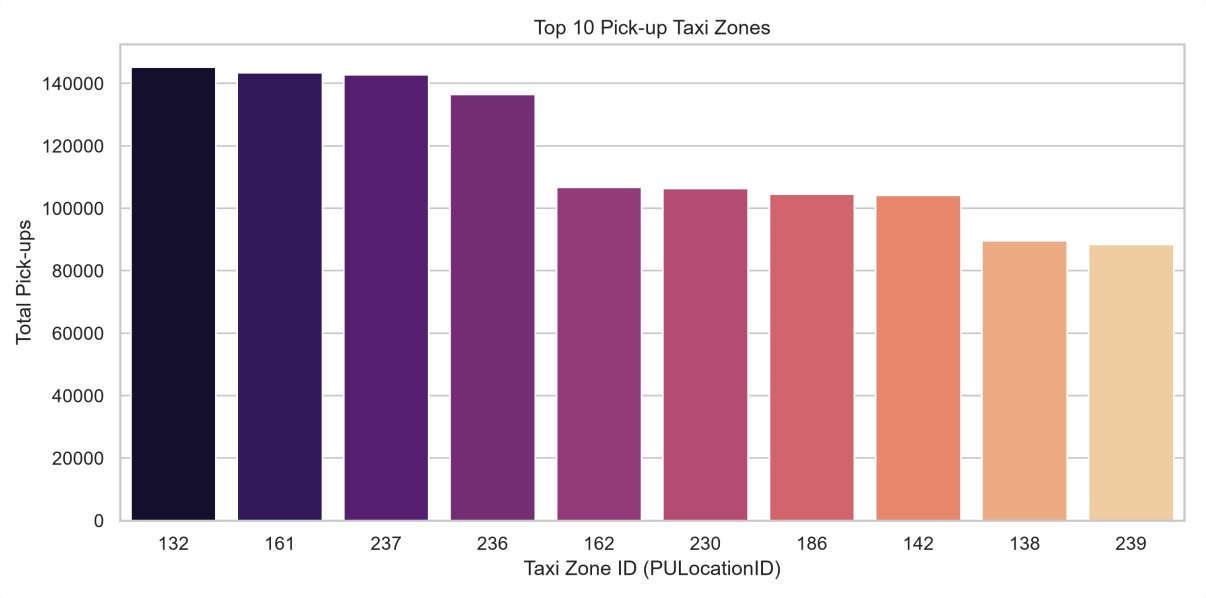
شکل ۱: توزیع فراوانی سفرهای تاکسی در ساعات مختلف شبانه‌روز

تحلیل نمودار ساعتی: همان‌طور که در شکل ۱ مشاهده می‌شود، کمترین میزان تقاضا در ساعات اولیه بامداد (بین ساعت ۴ تا ۵) رخ می‌دهد. با شروع فعالیت روزانه، تقاضا روند صعودی به خود گرفته و در ساعات عصرگاهی و اوایل شب (ساعات ۱۷ الی ۱۹) به نقطه اوج (Peak) خود می‌رسد که نشان‌دهنده تاثیر مستقیم ساعات بازگشت از محل کار بر تقاضای ناوگان است.



شکل ۲: توزیع تعداد سفرها در روزهای مختلف هفته

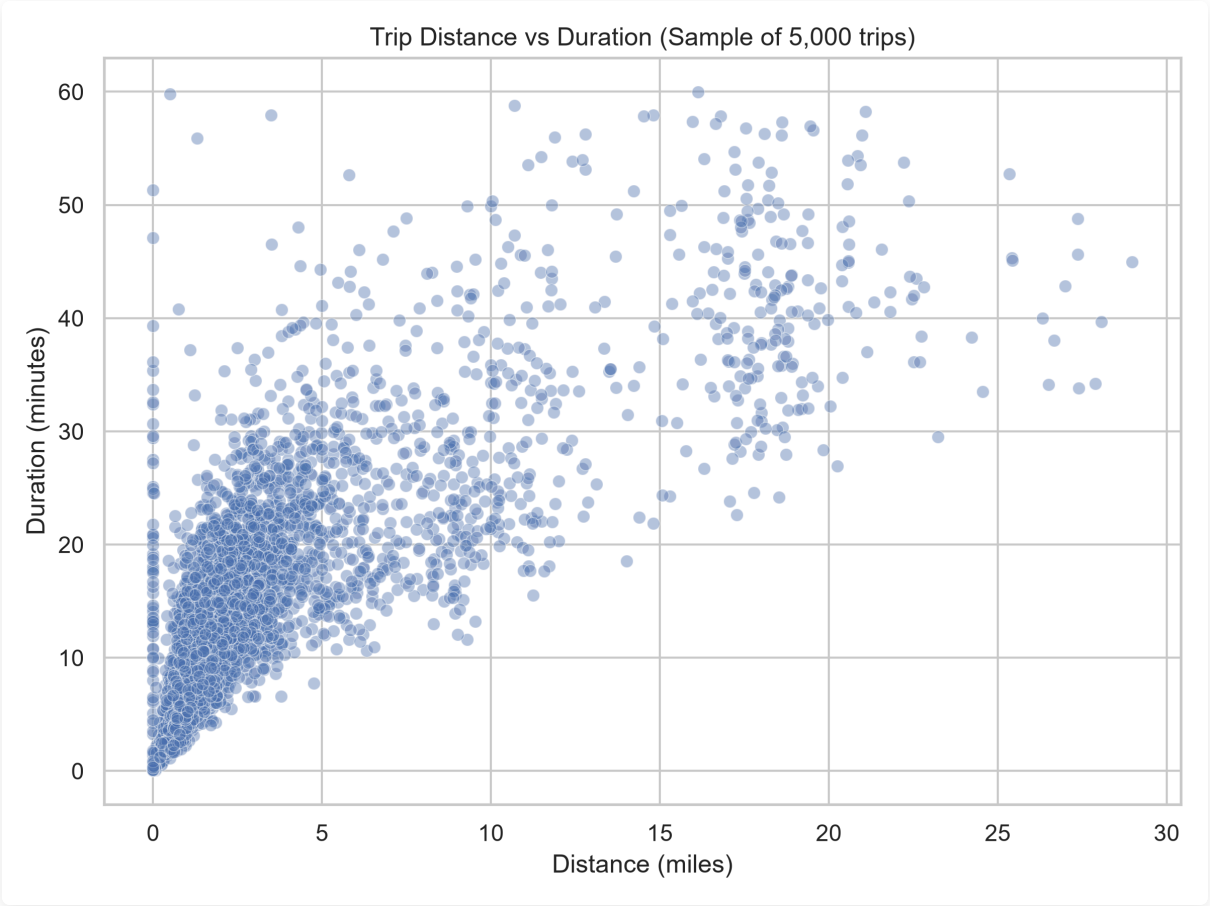
تحلیل نمودار روزانه: بررسی توزیع سفرها بر حسب روزهای هفته (شکل ۲) حاکی از آن است که روزهای پایانی هفته کاری (به‌ویژه پنج‌شنبه و جمعه) بیشترین حجم سفرهای شهری را ثبت کرده‌اند، در حالی که روزهای یکشنبه و دوشنبه تقاضای نسبتاً آرام‌تری دارند.



شکل ۳: ۱۰ منطقه پرتقاضا به عنوان مبدأ سفر (Top Pick-up Taxi Zones)

تحلیل ممیزی مکانی: نمودار میله‌ای ۱۰ منطقه برتر مبدأ (شکل ۳) نشان می‌دهد که توزیع تقاضای مکانی به شدت نامتوازن است و بخش قابل‌توجهی از سفرها از چند هاب اصلی (مانند مناطق مرکزی منهتن و ترمینال‌های مسافربری)

سرچشمه می‌گیرند که این موضوع ضرورت مدل‌سازی مکانی-زمانی را توجیه می‌کند.



شکل ۴: بررسی همبستگی میان مسافت سفر و مدت زمان (برش نمونه ۵۰۰۰ تایی)

تحلیل سازگاری متغیرها: نمودار پراکندگی مسافت در برابر مدت زمان سفر (شکل ۴) نشان‌دهنده همبستگی مثبت کلی این دو متغیر است. با این حال، وجود نقاط دورافتاده (Outliers) با مسافت صفر و زمان بالا، اهمیت پاک‌سازی دقیق داده‌ها در فاز دوم را دوچندان می‌کند.

۴. خط مبنا (Baseline) و ریسک‌های نشت اطلاعات (Leakage)

خط مبنای اولیه (Historical Baseline): استفاده از میانگین تقاضای تاریخی همان ساعت در روزهای مشابه هفته‌های گذشته به عنوان حد پایین عملکرد مدل‌ها در نظر گرفته می‌شود.

ریسک‌های نشت اطلاعات (Data Leakage):

- هرگونه تقسیم‌بندی تصادفی داده‌ها (Random Split) باعث نشت اطلاعات آینده به گذشته می‌شود. بنابراین حتماً از **تقسیم‌بندی زمانی (Temporal Split)** استفاده خواهد شد.

- پارامترهای نرمالسازی و پاک‌سازی داده‌ها صرفاً باید روی داده‌های آموزش (Train Set) محاسبه شوند.

۵. برنامه فاز بعدی

در فاز دوم، ساخت پایپلاین پیش‌پردازش برای حذف داده‌های ناصحیح، مهندسی ویژگی‌های چرخه‌ای زمان (Sin/Cos) و خوشه‌بندی مناطق بر اساس تقاضا انجام خواهد شد.